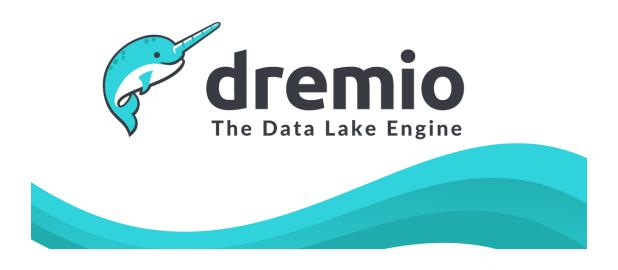
Dremio

Pedro González Fernández



16 de octubre de 2025

$\mathbf{\acute{I}ndice}$

1.	Instalando Dremio	2
2.	Trabajando con formatos en Dremio	5
2	Transformando datos on Dromio	19

1. Instalando Dremio

En esta actividad vamos a instalar y aprender a usar la herramienta Dremio. Para ello vamos a comenzar con la configuración inicial:

Creamos un usuario de sistema y el grupo asociado:

```
pedro@bda:~$ sudo groupadd -r dremio [sudo] contraseña para pedro:
pedro@bda:~$ sudo useradd -r -g dremio -d /var/lib/dremio -s /sbin/nologin dremio
pedro@bda:~$ 

pedro@bda:~$ cat /etc/group | grep dremio
dremio:x:985:

pedro@bda:~$ cat /etc/passwd | grep dremio
dremio:x:995:985::/var/lib/dremio:/sbin/nologin
pedro@bda:~$
```

También tenemos que preparar la estructura de directorios en /opt:

```
pedro@bda:~$ sudo mkdir /opt/dremio
pedro@bda:~$ sudo mkdir /opt/dremio/log
pedro@bda:~$ sudo mkdir /opt/dremio/run
pedro@bda:~$ sudo mkdir /opt/dremio/data
pedro@bda:~$ sudo chown -R dremio:dremio /opt/dremio
pedro@bda:~$ ls -lart /opt/dremio
total 20
drwxr-xr-x 7 root root 4096 oct 16 12:34 ..
drwxr-xr-x 2 dremio dremio 4096 oct 16 12:34 log
drwxr-xr-x 2 dremio dremio 4096 oct 16 12:34 run
drwxr-xr-x 2 dremio dremio 4096 oct 16 12:34 data
drwxr-xr-x 5 dremio dremio 4096 oct 16 12:34 .
pedro@bda:~$
```

Ahora vamos a descargar el software de la página oficial:

```
pedroglida-5 wet https://domload.drenio.com/community-server/23.6.5 2024070381116611 decard03/drenio.community-25.6.5 2024070381116611 decard03/drenio.community-25.6.5 2024070381116611 decard03/drenio.community-25.6.5 2024070281116611 decard03/drenio.community-25.6.5 2024070281116611 decard03/drenio.com/community-25.6.5 2024070281116611 decard03/drenio.com/community-25.6 2024070281116611 decard03/drenio.com/com
```

Lo descomprimimos en la ruta que hemos preparado:

```
pedro@bds.-6 | sudo tar .xvf dremio-comunity .25.0.5.20240782041140611-dca78083.tar .g. -6 | opt/dremio/.-strip-components-1|
dremio-comunity .25.0.5.2024078204110611-dca78083/jars/dremio-services-telemetry-impl: 25.0.20240782041108811-dca78083.jar
dremio-community .25.0.5.202407820411140611-dca78083/jars/dremio-services-telemetry-impl: 25.0.5.202407820411140611-dca78083.jars
dremio-community .25.0.5.202407820411140611-dca78083/jars/dremio-services-telemetry-impl: 25.0.5.20240782041140611-dca78083.jars
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-dac-daemon-25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-dac-ul-25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-ul-tib-25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-ul-to-community .25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-ul-to-community .25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-ul-to-community .25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-ul-to-community .25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-bdfs-plugin-25.0.5.20240782041140611-dca78083.jar
dremio-community .25.0.5.20240782041140611-dca78083/jars/dremio-bdfs-plugin-25.0.5.20240782041140611-dca78083/jar
```

```
pedro@bda:~$ sudo chown -R dremio:dremio /opt/dremio/
pedro@bda:~$ ls -lart /opt/dremio/
total 64
                             4096 jul
drwxr-xr-x
           2 dremio dremio
                                           2024 licenses
            2 dremio dremio
                             4096 jul
                                           2024 bin
drwxr-xr-x
                             4096 oct 16 12:34
            7 root
                     root
             dremio dremio
                             4096 oct
                                          12:34 log
                             4096 oct
                                       16 12:34 run
            2 dremio dremio
             dremio dremio
                             4096 oct
                                          12:34 data
            3 dremio dremio
                             4096 oct 16 12:39 plugins
             dremio dremio 20480 oct 16 12:39
                                                jars
lib
              dremio dremio
                             4096 oct
             dremio dremio
                             4096 oct 16 12:39 share
            2 dremio dremio
                             4096 oct 16 12:39 conf
                             4096 oct 16 12:39
drwxr-xr-x 12_dremio dremio
```

Una vez hecho, vamos a crear un enlace simbólico de la configuración en /etc y copiamos el servicio para el arranque:

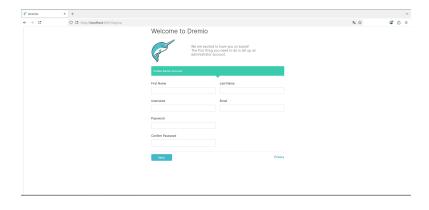
```
pedro@bda:~$ sudo ln -s /opt/dremio/conf /etc/dremio
pedro@bda:~$ sudo cp /opt/dremio/share/dremio.service /etc/systemd/system
```

Arrancamos dremio y, cuando finalice, lo configuramos para que se arranque al iniciar:

```
pedro@bda:~$ sudo systemctl daemon-reload
pedro@bda:~$ sudo systemctl start dremio
pedro@bda:~$ sudo systemctl status dremio
● dremio.service - Dremio Daemon Server
Loaded: loaded (/etc/systemd/system/dremio.service; disabled; preset: enabled)
Active: active (running) since Thu 2025-10-16 12:42:07 CEST; 30s ago
Docs: https://docs.dremio.com
Main PID: 2912 (java)
Tasks: 51 (limit: 9365)
Memory: 1.06 (peak: 1.06)
CPU: 52.871s
CGroup: /system.slice/dremio.service
L2912 /usr/lib/jvm/java-11-openjdk-amd64/bin/java -Djava.util.logging.co
```

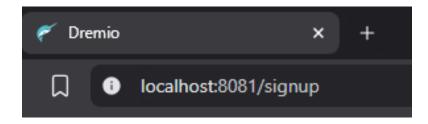
```
pedro@bda:-$ sudo systemctl enable dremio
Created symlink /etc/systemd/system/multi-user.target.wants/dremio.service → /etc/systemd/system/dremio.service.
pedro@bda:-$ ■
```

Finalmente, vamos a comprobar si podemos acceder:



Como paso extra, voy a configurar un reenvio de puerto en la máquina virtual para acceder a dremio desde el host:

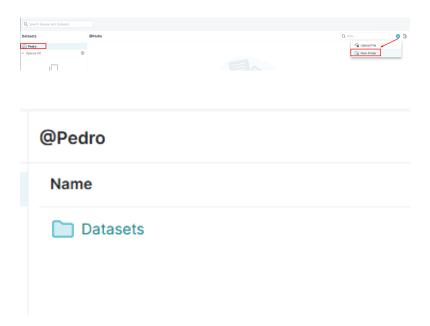




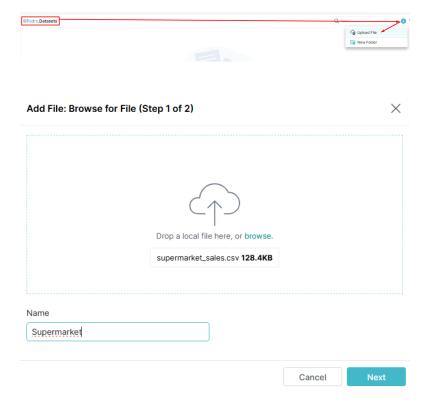
2. Trabajando con formatos en Dremio

En este apartado vamos a usar un dataset de muestra y hacer operaciones con él en diferentes formatos.

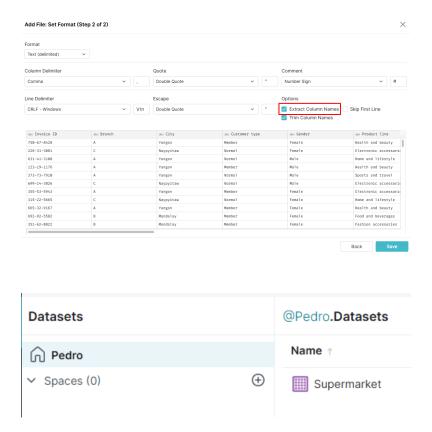
Primero creamos una carpeta en dremio para guardar todos los ficheros:



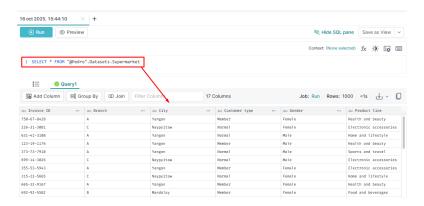
Dentro de la carpeta, tenemos que subir el archivo csv de muestra:



Al subirlo, tenemos que activar la opción para que extraiga los nombres de las columas y no los trate como un registro más:



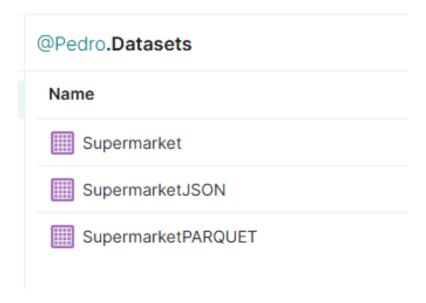
Si entramos en el dataset, podemos hacer consultas como si de una base de datos se tratase:



Hacemos una consulta para mostrar todos los datos y vamos a descargar este resultado en dos formatos, en JSON y en PARQUET:



Y subimos los ficheros a Dremio como hicimos con el csv inicial:



Ahora vamos a lanzar una consulta de prueba en cada uno de los datasets para comprobar que dataset la realiza más rápido:

■ CSV:



■ JSON:

■ PARQUET:



Podemos revisar los detalles de los trabajos:



Summary

Status: COMPLETED

Total Memory: 4.39 GB CPU Used: 01m:52s

Query Type: UI (run)

Start Time: 16/10/2025 15:54:28

Duration: 39.83s

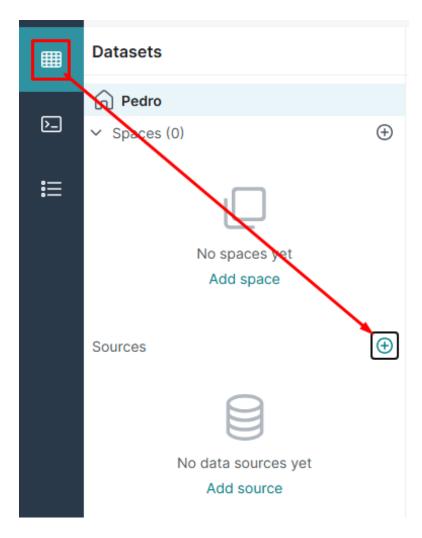
Wait on Client: <1s

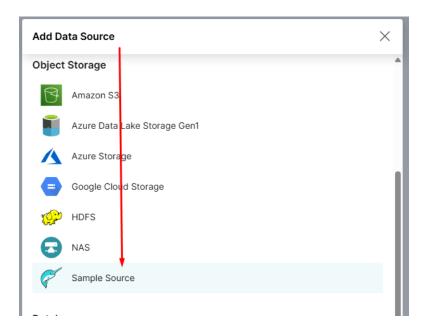
User: Pedro Queue: LARGE

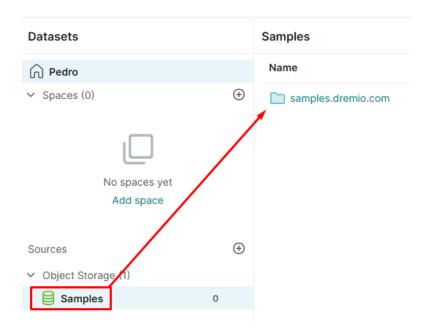
Input: 283.27 KB / 6K Rows

Output: 253.40 KB / 1.9K Rows

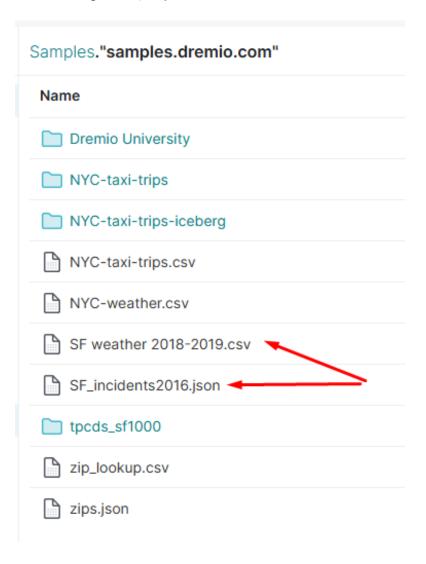
Finalmente, vamos a realizar una comprobación. Queremos saber si PARQUET es autodescriptivo. Para esto vamos a cargar datos de prueba y crear un dataset a partir de un fichero parquet.



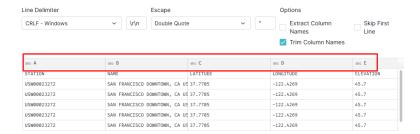




Dentro de los datos de prueba, hay varios ficheros en distinto formato:



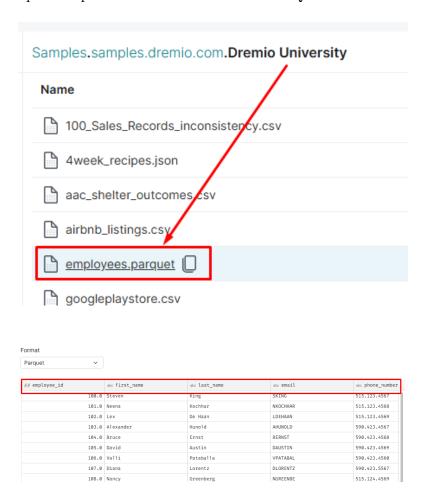
Si miramos el csv, podemos ver que este no es autodescrptivo:



Sin embargo, si miramos el JSON, veremos que si lo es:



Vamos a comprobar que ocurre con un archivo PARQUET.

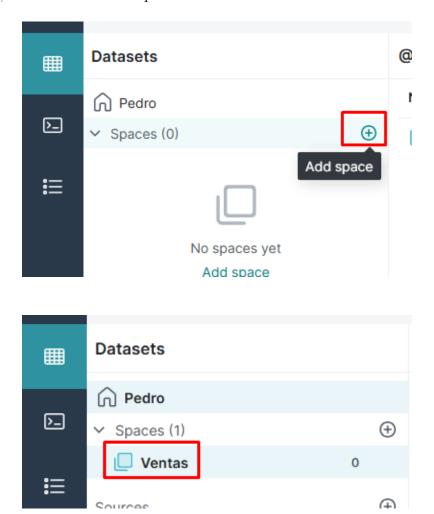


Como podemos observar, PARQUET si es autodescriptivo.

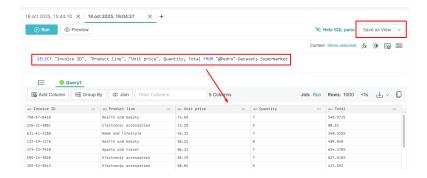
3. Transformando datos en Dremio

En este apartado vamos a empezar a partir de un dataset y vamos a transformar los datos a nuestra elección.

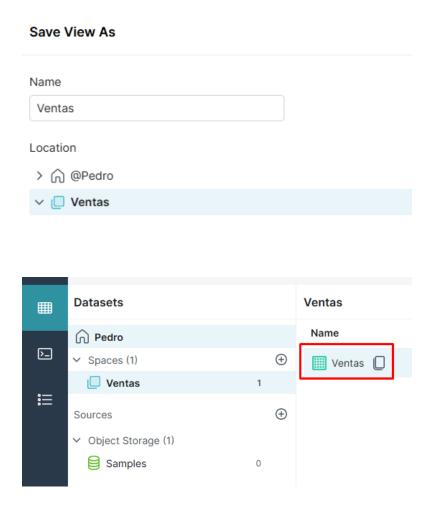
Para ello, vamos a crear un espacio llamado 'Ventas':



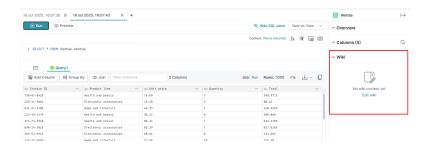
Ahora vamos a realizar una consulta a la tabla Supermarket y guardamos el resultado como un dataset nuevo dentro del espacio que hemos creado:



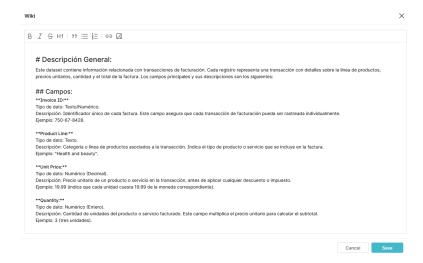
Lo guardamos como 'Ventas':



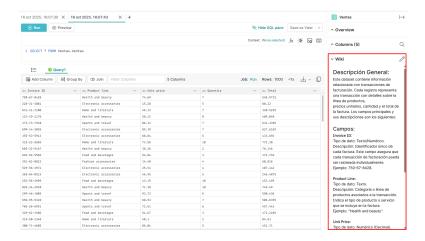
Lo primero que vamos a hacer es crear una wiki del dataset. Esto nos permite tener la documentación dentralizada, aportando contexto y trazabilidad a los datos.



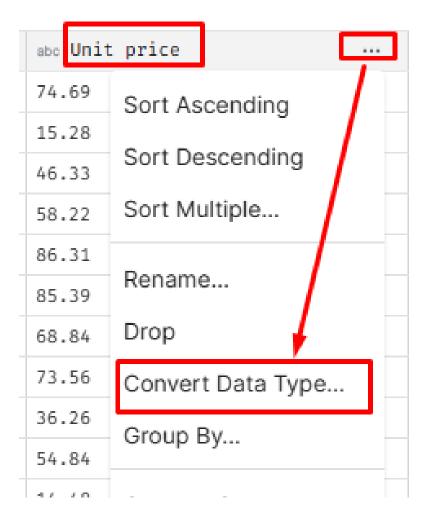
Añadimos una descripción al dataset:



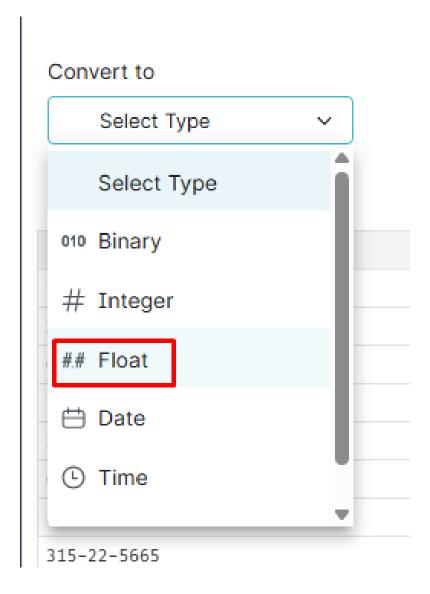
Y ahora, cuando hagamos consultas, podemos tener la documentación siempre a mano:



Lo siguiente que vamos a hacer es cambiar los tipos de datos. Empezaremos por cambiar a formato número (float o entero) los campos numéricos pero que estan puestos en formato texto. Seleccionamos el campo y le damos a 'Convert data Type...'



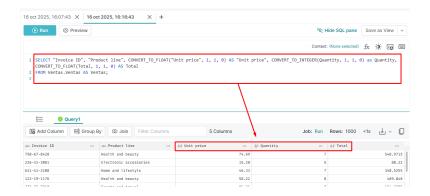
Dentro, ponemos el tipo de campo al que queremos convertirlo:



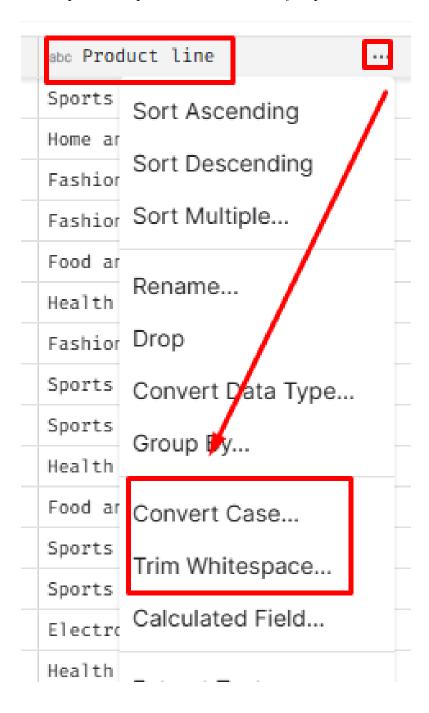
Y vemos un preview del resultado:

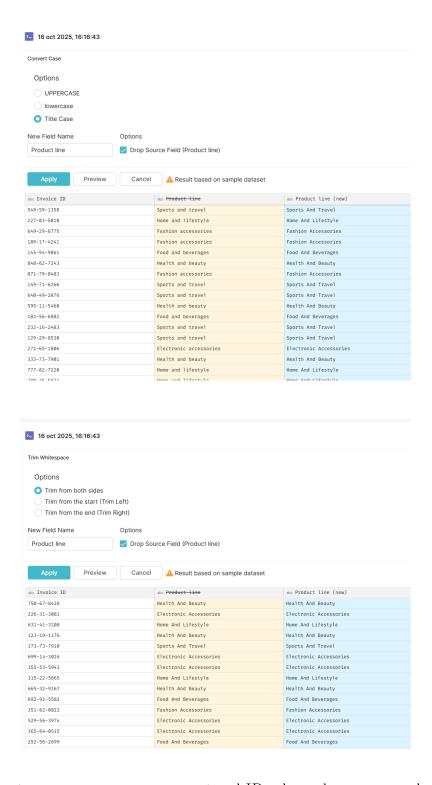


Si aplicamos, vemos la consulta generada automáticamente para la conversión del tipo. Si repetimos el proceso con el resto de campos, llegamos a este resultado:

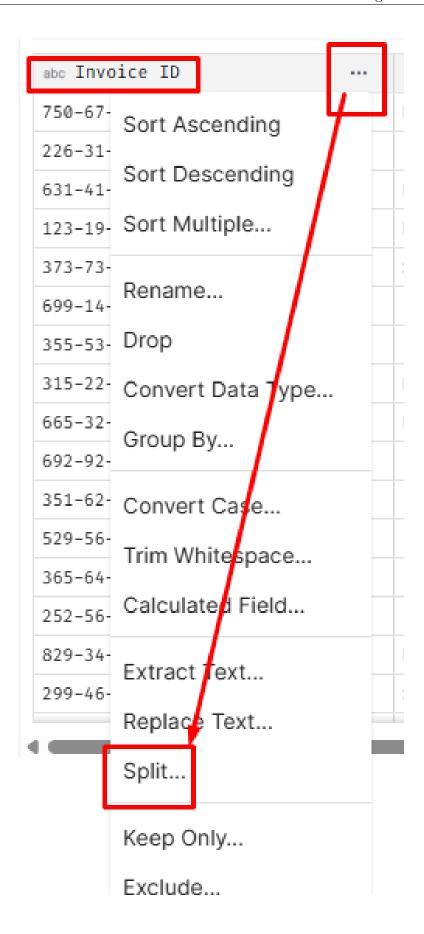


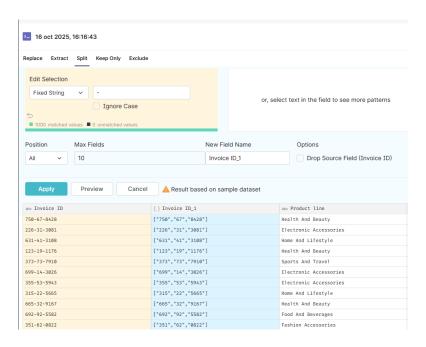
Ahora vamos a limpiar los espacios de las cadenas y capitalizar el texto:



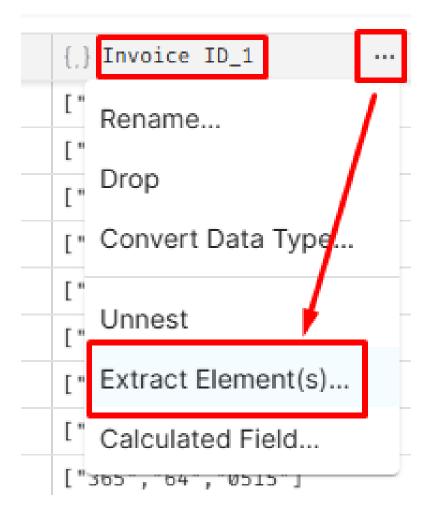


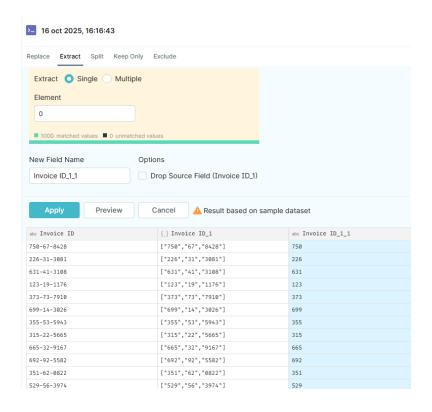
Y, finalmente, vamos a separar por partes el ID y luego lo vamos a volver a unir:

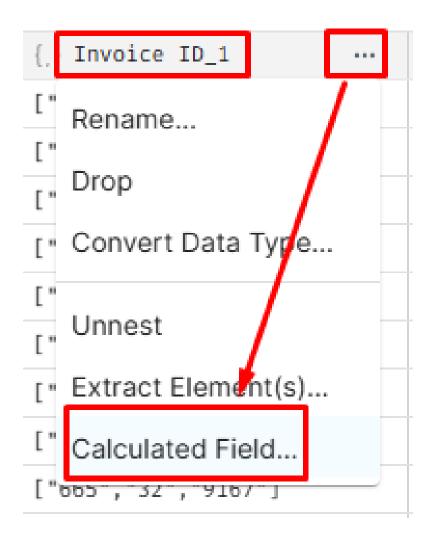


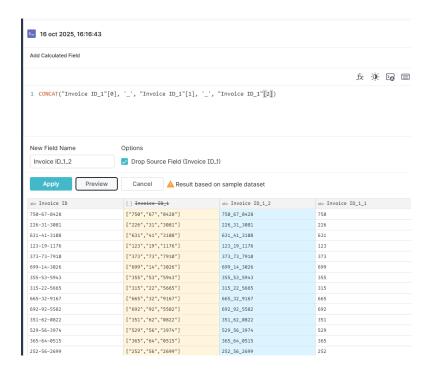


* Aquí es importante no borrar el campo original.









La consulta final quedaría así:

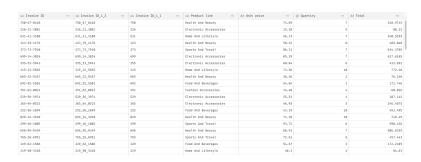
```
SELECT 'Invoice ID', COMCAT('Invoice ID_1"[0], '_', 'Invoice ID_1"[1], '_', 'Invoice ID_1"[2]) AS "Invoice ID_1_2", 'Invoice ID_1_1", 'Product Ine", 'Unit price", Quantity, Total FROM (

SELECT 'Invoice ID', 'Invoice ID', 'Invoice ID_1"[0] AS 'Invoice ID_1_1", 'Product line", 'Unit price", Quantity, Total FROM (

SELECT 'Invoice ID', 'Regeo, split('Invoice ID', '\Q_\k', 'ALL', 10) AS 'Thvoice ID_1", 'tria(both '' from ITILE('Product line")) AS 'Product Ine", COMVERT_TO_ENDRETO_TOTAL('Ventas'. 'Unit price", 1, 1, 0) AS 'Unit price", CONVERT_TO_INTEGER('Ventas'. 'Quantity', 1, 1, 0) AS Quantity, 'ROMCRIT OF LORIT', 'ALL', 'ID', 'AS TOTAL INTEGER ('Ventas', 'Quantity', 1, 1, 0) AS Quantity, 'ROMCRIT OF LORIT', 'AS AS Ventas ') nested_0

) nested_1;
```

Y mostraría este resultado:



Vamos a guardarlo como un dataset en el espacio de ventas:

